改进①：Q-Ensemble 悲观打分

面向小样本抗干扰的动作推荐打分改进

Round 20261007 | 组会汇报

一、任务与基线架构

- 任务：给定干扰状态 S（干扰类型、功率、载频等），从候选雷达动作 A（载频 / 增益 / 带宽 / 脉宽 / 类型 / 调制）中推荐预测 SINR 最高的动作。
- 基线管线（Round2 确认的最优形态 Retrieve+Q-Union）：

  S → 冻结 VAE 编码为潜向量 z（128 维）→ 按同类干扰余弦相似度检索 Top-5 相似训练场景 → 其动作构成检索候选池，再并入随机 100 个动作组成大池（约 200 个）→ QRetrievalNet(z, z_ctx, A) 逐一打分 → argmax。
- QRetrievalNet 的上下文 z_ctx：Top-5 邻居潜向量按相似度 softmax(τ=0.07) 加权均值；训练目标 = MSE 回归 + listwise ranking loss（池内 argmax Q 对齐 argmax 真值）。
- Round2 成绩（50 个留出场景）：regret −5.08 dB，零 regret 84%，对 q_only 胜率 90%。

二、动机：单模型 Q 的两个痛点

- 痛点 1（打分随机性）：Q 网络训练存在种子级随机性，单模型在约 200 个候选的大池上argmax 时，容易被偶然高分的动作带偏——这类动作往往是检索先验覆盖之外的随机动作。
- 痛点 2（小样本过度自信）：在稀有干扰类型、低检索相似度的场景，检索先验本身证据不足，单模型仍给出确定的点估计，无法表达「我不确定」，容易在小样本场景翻车。
- 目标：不追求全体场景平均 regret 最低，而是提升小样本 / 检索证据弱场景的稳健性（减少坏案例），这正是抗干扰部署最关心的指标。

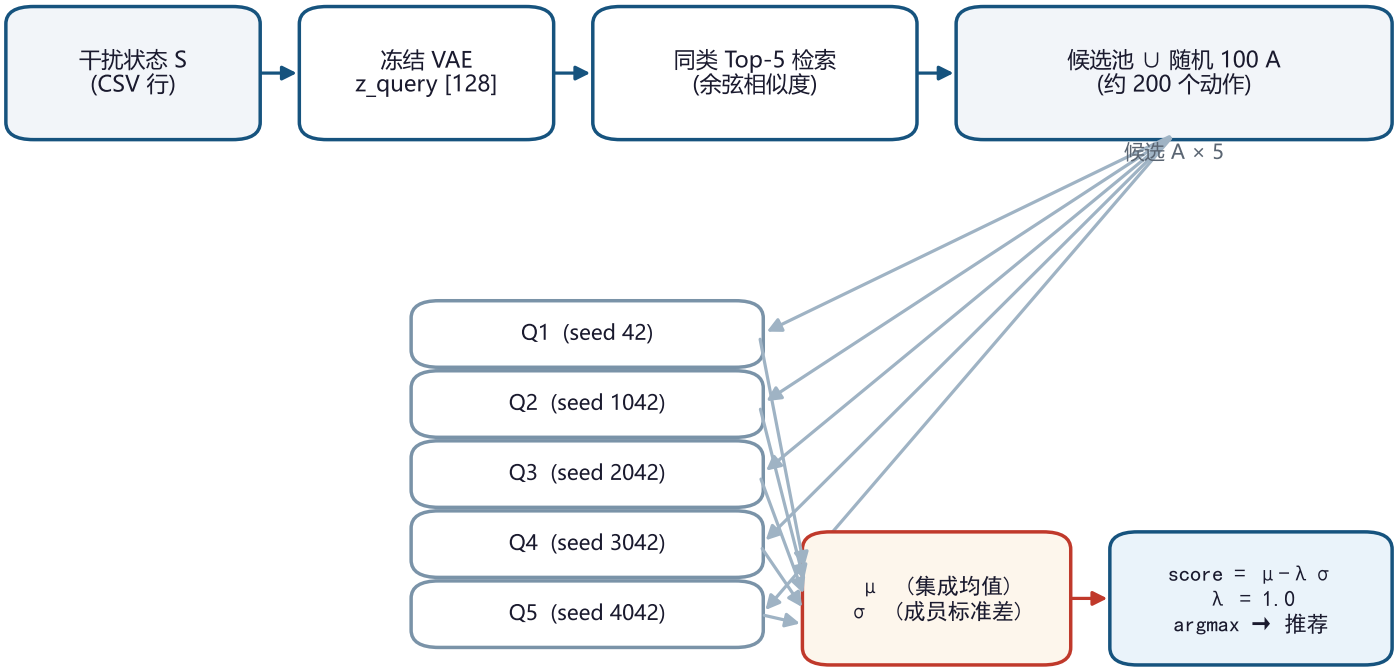
三、一句话概括改进①

训练 5 个不同种子的 Q 网络（其余协议完全相同），推理时用「集成均值 − 1×集成标准差」悲观打分：成员间分歧大的候选动作被自动降权，优先选择大家一致认可的动作。

方法：深度集成 + 悲观打分 μ − λ σ

改进① 的完整打分流程与训练协议

1. 打分流程



候选池 = 检索池（Top-5 相似场景的动作）∪ 随机 100 A

5 个成员仅训练种子不同，其余训练协议完全一致

2. 关键设计点

- 深度集成（5 seeds）：seed = 42 / 1042 / 2042 / 3042 / 4042，数据、场景级划分、warm-start、超参全部与 Round2 单模型一致——唯一变量是种子，集成差异纯粹反映训练随机性。
- 悲观打分 score = μ − λσ：σ 是 5 个成员对同一候选动作打分的标准差（模型间分歧），分歧大的动作被降权；λ= 1.0 未调参。
- 大池统一打分：检索池与随机探索动作同规则同尺度——无需显式设定「先验 vs 探索」的融合权重，由 σ 隐式完成。

3. 训练协议（与 Round2 完全对齐，保证公平对比）

- 数据：Round2 信号级重标注（RadarSimPy 信号级仿真 SINR，JSR=10 dB），10k 场景 × 10 动作。
- 损失：MSE + 0.5×listwise ranking loss（检索候选池内 argmax Q 对齐 argmax R），每 epoch 32 步 × 4 场景。
- 优化：Adam lr=1e-3，weight decay 1e-4，batch 256，≤300 epoch；早停 = 验证集检索池 Oracle Hit@1（patience 25）。
- 集成成员质量：val Hit@1 = 0.57 / 0.56 / 0.59 / 0.63 / 0.56（与 Round2 单模型同水平）。

实验设置与主结果

50 个留出场景 · 信号级真值 · regret 相对 Oracle-K20

1. 实验设置

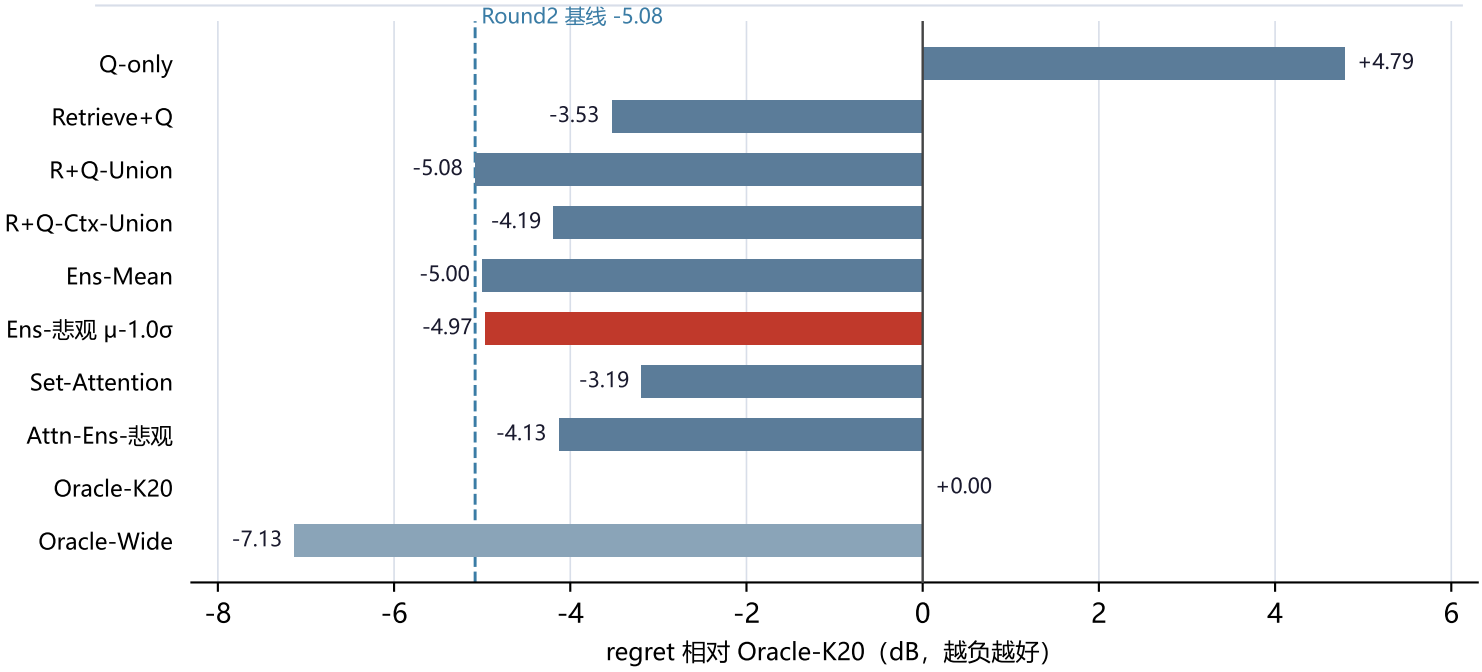
- 留出条件：前 50 个未见干扰场景（holdout seed=2026），每场景候选约 200 个动作；真值为 RadarSimPy 信号级仿真（JSR=10 dB），所有方法完全同池同真值。

- 指标：regret = Oracle-K20（留出 K=10 随机动作上界）− 推荐动作 SINR，越负越好；另报中位 regret（稳健性）、零 regret 占比、对 q_only 的逐场景配对胜率。

2. 主结果表

方法	推荐SINR(dB)	regret(dB)	中位regret	零regret	胜率vs q_only
Q-only（无检索基线下限）	12.46	+4.79	+2.36	32%	—
Retrieve+Q（Top-5 池）	20.78	-3.53	-1.43	76%	82%
Retrieve+Q-Union（Round2 最优基线）	22.33	-5.08	-1.89	84%	90%
Retrieve+Q-Ctx-Union（最优 ctx 变体）	21.44	-4.19	-2.00	80%	88%
① Ensemble-Mean（5×Q 取均值）	22.26	-5.00	-2.57	84%	90%
① Ensemble-悲观 μ-1.0σ（本轮方法）	22.22	-4.97	-3.08	82%	96%
② Set-Attention 单模型（对照）	20.45	-3.19	-1.89	72%	90%
①+② Attention-Ens-悲观（对照）	21.38	-4.13	-2.10	76%	90%
Oracle-K20（留出上界）	17.25	+0.00	+0.00	100%	68%
Oracle-Wide（100 随机 A 上界）	24.38	-7.13	-3.68	92%	94%

3. 结果柱状图



要点：平均 regret 上集成悲观（−4.97）与 Round2 最优基线（−5.08）持平；但中位 regret 最优（−3.08，基线 −1.89），对 q_only 配对胜率 96%（基线 90%）——均值没赢，坏案例显著变少。

小样本分桶：改进①的目标场景

按检索证据强弱二分（中位数切分）——证据越弱，集成悲观领先越多

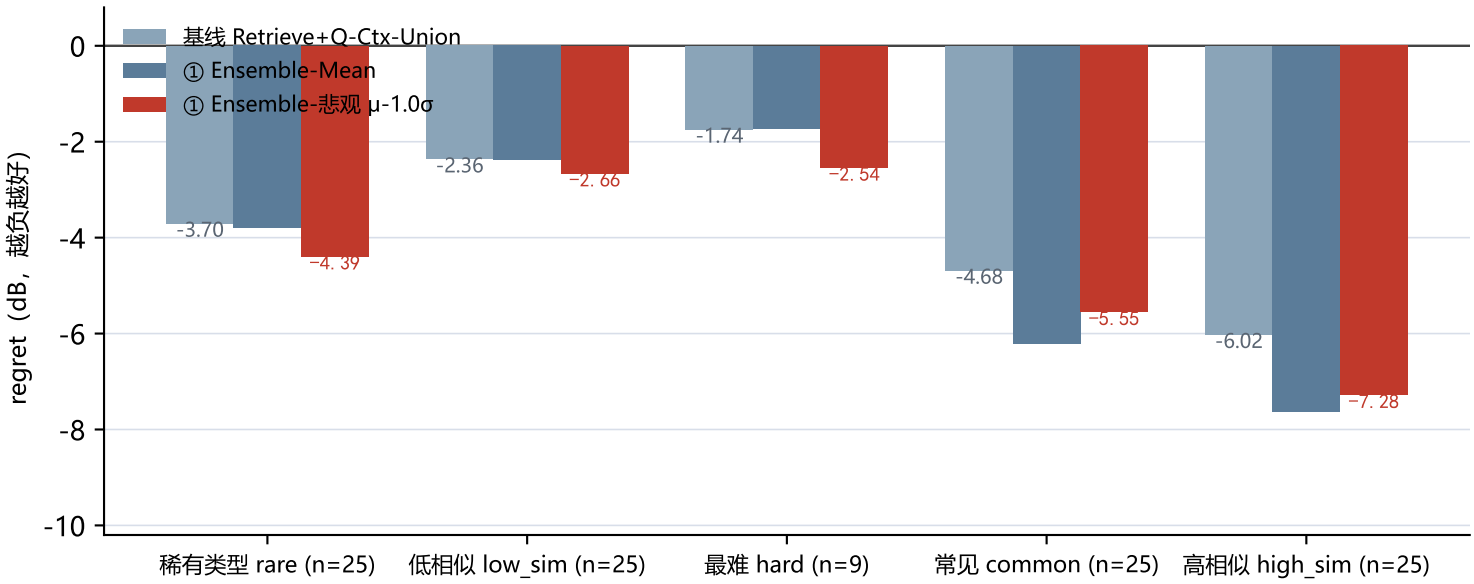
1. 分桶定义

- rare_type / common_type：按「训练库中同类干扰场景数」中位数（567.5）二分；
- low_sim / high_sim：按查询与检索库 Top-1 余弦相似度中位数（0.931）二分；
- hard = rare_type ∩ low_sim（n=9）：检索证据最弱的子集——本轮改进的核心靶点。

2. 分桶结果表

桶 (n)	Q-only	基线 Ctx-Union	① Ens-Mean	① Ens-悲观	悲观胜率
稀有干扰类型 rare_type（n=25）	+1.66	−3.70	−3.80	−4.39	96%
低检索相似度 low_sim（n=25）	+2.22	−2.36	−2.38	−2.66	96%
最难子集 hard（n=9）	+1.42	−1.74	−1.73	−2.54	100%
常见类型 common_type (n=25)	+7.93	-4.68	-6.21	-5.55	—
高检索相似度 high_sim (n=25)	+7.37	-6.02	-7.63	-7.28	—

3. 分桶柱状图（三个「检索证据弱」桶 + 两个对照桶）



要点：rare_type / low_sim / hard 三个桶上集成悲观全面最优（hard 桶 regret −2.54 vs 基线 −1.74，对 q_only 胜率 100%）；检索证据充足的 common_type / high_sim 桶上基线仍略优——改进①把「保守」花在了它该花的地方。

σ 诊断、结论与后续

对机制的诚实检验 + 已落地的默认推荐路径

1. σ 诊断：机制假设部分证伪

方法	全池平均σ	检索池动作σ	随机池动作σ
① Ensemble（μ 与 μ−σ 同 σ）	0.2670	0.2657	0.2684
①+② Attention-Ensemble	0.4663	0.4678	0.4650

- 设计初衷假设「随机池动作（检索先验外）σ 更大，悲观打分会自动压低它们」——数据显示检索池与随机池 σ 仅差 0.9%（0.2657 vs 0.2684），该机制未获支持。
- 真实收益来源：集成平均本身比单模型更准（降噪），μ−σ 再把成员分歧大的候选压低——体现为中位 regret 由 −2.57（仅取 μ）进一步改善至 −3.08，尾部坏案例减少。

2. 结论与采纳

- 改进①有效，且收益集中在目标场景：小样本分桶（rare_type / low_sim / hard）全面最优，hard 桶对 q_only 胜率 100%；全体场景配对胜率 96%（全场最高）。
- 已采纳为默认推荐打分方式：官方推理 API radar/infer/q_ensemble.py（QEnsembleRecommender，λ=1.0，5 seeds）；与存档评估逐场景对拍 50/50 精确一致。
- 改进②（Set-Attention 上下文）本轮仅保留接口（支持任意邻居库注入），不进主流程，待 k-shot 实测样本实验后再判定——其单模型在 hard 桶优于基线（−2.44 vs −1.74），有潜力信号。

3. 局限与下一步

- 统计功效有限：50 个场景、hard 桶仅 9 个，胜率差（96% vs 90%）方向可信、幅度待更多场景验证；
- σ 区分度弱：可尝试让网络显式输出不确定性（log-variance 头 / 最后层贝叶斯化），或按「候选与检索库的距离」外生构造 σ，恢复「压低池外动作」的机制；
- k-shot 实测样本：用改进②的邻居集合接口，把检索库替换 / 混入少量实测场景样本，检验小样本实测适配能力——这是两项改进共同的下一步。

附：产物位置（outputs/20261007_fewshot/）— 代码 code/ | 模型 models/q_ensemble/ | 评估 eval_fewshot/summary.json | 报告 comparison_report.md